

제 4회 BDAI 채용 연계 데이터 분석 공모전

팀 사달라

조문영 정민우 조용진 조정화



목차

01 모델링 과정 및 선정

- 탐색적 데이터 분석(EDA) 및 전처리
- 적용한 모델 구조 및 학습 방식
- 모델 선정 및 성능 비교

02 문제 정의 및 솔루션

- 문제 정의
- 제안 배경
- 솔루션 구체화

03 결론 및 고찰

- 기대 효과
- 아쉬웠던 점

01 모델링 과정 및 선정

모델링 과정 및 선정

탐색적 데이터 분석(EDA) 및 전처리

데이터 선택

activePower 기반 분석
(1시간 집계)

시계열 특성 추출

Lag1, Lag24, Rolling 24

변수 추가

시간(*Hour*), 요일(*dayofweek*)
변수 추가

가동 여부 기반


설비 미가동 시 (*operation = 0*)
예측값 0 처리

외부 데이터

기상청 데이터 → 상관계수 0에 수렴

모델링 과정 및 선정

탐색적 데이터 분석(EDA) 및 전처리 - 데이터 선택



데이터 특징

- 결측치, 이상치 존재 $\times$
- 38,000 ~ 39,500 범위 내 안정적 유지

전처리

- 전력 사용량 예측이 목적이므로
시계열 패턴과 반복 구조 학습이 핵심
- 5초 $\rightarrow$ 1시간 집계

모델링 과정 및 선정

탐색적 데이터 분석(EDA) 및 전처리

데이터 선택

activePower 기반 분석
(1시간 집계)

시계열 특성 추출

Lag1, Lag24, Rolling 24

변수 추가

시간(*Hour*), 요일(*dayofweek*)
변수 추가

가동 여부 기반

설비 미가동 시 (*operation = 0*)
예측값 0 처리

외부 데이터

기상청 데이터 → 상관계수 0에 수렴

모델링 과정 및 선정

탐색적 데이터 분석(EDA) 및 전처리 - 시계열 특성 변수 생성



Lag 1 직전 1시간 전력

- 1시간 전 시간의 전력 사용량을 변수로 활용
- 단기 추세를 반영하여 급격한 변동에 대응

Lag 24 전일 동시간 전력

- 24시간 전 동일 시간대의 전력 사용량
- 일별 주기성을 반영하는 핵심 변수

Rolling 24 이동 평균

- 최근 24시간 동안의 평균 전력 사용량
- 노이즈를 제거한 장기 추세 및 기준선 파악

모델링 과정 및 선정

탐색적 데이터 분석(EDA) 및 전처리

데이터 선택

activePower 기반 분석
(1시간 집계)

시계열 특성 추출

Lag1, Lag24, Rolling 24

변수 추가

시간(*Hour*), 요일(*dayofweek*)
변수 추가

가동 여부 기반


설비 미가동 시 (*operation = 0*)
예측값 0 처리

외부 데이터

기상청 데이터 → 상관계수 0에 수렴

모델링 과정 및 선정

탐색적 데이터 분석(EDA) 및 전처리 - 변수 중요도 분석



1st Rolling 24 (장기 추세)

전반적인 전력 사용량의 베이스라인 역할을 수행하며 추세를 반영

2nd Lag 24 (전일 동시간)

24시간 전 동일 시간대의 전력 패턴이 현재 예측에 영향을 미침

3rd Lag 1 & Hour

단기적인 변동성과 하루 중 시간대별 패턴을 보완

모델링 과정 및 선정

적용한 모델 구조 및 학습 방식

Train	Val
2,879행, 80.5%	697행, 19.5%
2024.12.01~2025.03.31	2025.04.01~2025.04.30

Boosting Algorithms

XGBoost

순차적인 트리 생성을 통해 이전 모델의 오차를 보정하고 정규화 기법으로 과적합을 효과적으로 제어함

LightGBM

Leaf-wise 성장 방식을 채택하여 대용량 데이터 처리 속도가 매우 빠르고 메모리가 효율적임

CatBoost

Symmetric Tree를 사용하여 예측 속도가 안정적이며 내장된 과적합 방지 기능이 우수함

Bagging Algorithms

Random Forest

여러 개의 의사결정 트리를 독립적으로 학습시켜 그 결과를 Voting/Averaging하는 방식

Time Series Models

Prophet

계절성과 추세 기반 여러 요소의 가법 모델로 데이터의 변화를 분석하고 미래를 예측하는데 성능이 우수함

ARIMA

과거 패턴을 분석하여 미래를 예측하는 통계 모델로 자기회귀, 차분, 이동평균 세 가지 요소를 결합함

모델링 과정 및 선정

적용한 모델 구조 및 학습 방식 - 모델 튜닝

Tuning Strategy

Grid Search 기반의 최적 파라미터 탐색
Learning Rate를 낮추고 Estimator 수를
늘려 정밀도 향상
Tree Depth 제한으로 모델 과적합 방지

Target Models

튜닝이 적용된 주요 모델

XGBoost

LightGBM

CatBoost

RandomForest

PARAMETER	DEFAULT SETTING	TUNED SETTING (OPTIMIZED)
<i>n_estimators</i>	100 (RF, XGB) Auto (LGBM)	1,000 (All Tree Models) → 충분한 학습량 확보
<i>learning_rate</i>	0.1 ~ 0.3	0.03 (Lower Learning Rate) → 과적합 방지 및 안정적 수렴
<i>max_depth</i>	None (RF) 6 (XGB)	6 ~ 15 (Model Specific) → XGB(6), LGBM(10), RF(15)
<i>min_samples_split</i>	2	5 (RandomForest) → 노드 분할 제약 강화
<i>num_leaves</i>	31 (LGBM Default)	64 (LGBM Only) → 모델 복잡도 최적화

모델링 과정 및 선정

모델 선정 및 성능 비교 - 학습 파이프라인

Voting Regressor


- SMAPE 기준 상위 2개 모델 선정
- 예측값의 평균을 산출하여 최종 예측
- 간단하지만 분산 감소 효과

Stacking Regressor

- Base Model: SMAPE 기준 상위 2개 모델 선정
- Meta Model: Ridge Regression 활용
- 모델 간 약점을 상호 보완


효과: 단일 모델 대비 안정성 향상 및 과적합 방지

ENSEMBLE PROCESS FLOW




모델링 과정 및 선정

모델 선정 및 성능 비교 - 최종 모델 성능 지표



모델링 과정 및 선정

모델 선정 및 성능 비교- 검증 데이터 예측 성능



VALIDATION PERIOD

2025.04.01 - 2025.04.30

SMAPE

0.197 %

실제 전력 사용 패턴과
모델 예측값의 높은 일치도 확인

02 문제 정의 및 솔루션


문제 정의 및 솔루션

문제 정의

1 이상 설비 발견 시
사후 대응 한계



2 비효율적인 전력 소비 패턴에 따른
전력 요금 낭비



문제 정의 및 솔루션

제안 배경


1 이상 설비 발견 시 사후 대응 한계



→ 이상 전력 패턴 탐지 및 알림 서비스

EDA 결과, 공장 전력 소비 패턴의 변동성이 낮아 예측값 대비 전력 사용량의 이탈을 설비 이상 신호로 판단

2 비효율적인 전력 소비 패턴에 따른 전력 요금 낭비




→ TOU 기반 전력 스케줄링

선형계획법(LP)를 활용한 전력 스케줄링 최적화

: 피크 전력 저감 및 전력 스케줄 이동(고비용 시간대 → 저비용 시간대)

이상 전력 패턴 탐지 및 알림 서비스



위험 구간 설정

전력 사용량 분포의 $\mu \pm 2.58\sigma$ 를 벗어나는 구간으로 설정

설비 이상 알림 시스템


전력 사용량이 위험 구간 진입 시 사전 경고 알림 설정

자동 원인 분석

전류 불평형 계산을 통한 전류 과부하가 일어난 상 자동 추적

이상 전력 패턴 탐지 및 알림 서비스

모바일 화면 알림 UX 예시



Swipe up to unlock

09:41



Power Alert

⚠ 전력 이상 감지

설비 : 분쇄기 1

전력 사용량 기준치 초과

전류 불평형 : 9.8%

-> R상 전류 과부하 탐지



Power Alert

⚡ 특정 설비 이상 가능성
냉난방 시스템 사용량이 비정상적으로 높음



Power Alert

⚡ 장비 사용 패턴 이상
특정 구간에서 전력 소비가 집중

전력 요금 절감: TOU 기반 전력 스케줄링

선형계획법(LP) 기반 전력 사용 최적화

Objective : Min (전력량 요금 + 기본 요금 + 변동성 억제)

$$\text{Minimize } Z = \sum_{t=1}^T (C_t * P_t) + \alpha * P_{peak} + \beta \sum_{t=2}^T |P_t - P_{t-1}|$$

$$1) \sum_{t \in D_k} P_t = E_{total,k} \quad (\forall k \in Days)$$

$$2) |P_t - P_{t-1}| \leq \Delta P_{limit} \quad (\forall t)$$

$$3) P_t \leq P_{peak}$$

$$4) P_{min} \leq P_t \leq P_{max}$$

P_t : 시간 t 의 최적 전력 사용량(kW)

P_{peak} : 월간 최대 수요 전력(kW)

C_t : 계시별 요금 단가 (원/kWh)

α : 기본요금 단가 (원/kW)

β : 변동성 억제 가중치


$E_{total,k}$: 기존 일일 총 전력 소비량(kWh)

ΔP_{limit} : 시간당 허용 최대 변동폭 (kW)

$P_{min/max}$: 설비 가동 최소/최대 한계값

전력 요금 절감: TOU 기반 전력 스케줄링

선형계획법(LP) 기반 전력 사용 최적화



5월 전력 예측량 기준

34억 9920만원

5월 최적 전력량 기준


34억 9880만원

03 결론 및 고찰


결론 및 고찰

기대 효과

1 이상 전력 패턴 탐지 및 알림 서비스




2 TOU 기반 전력 스케줄링



결론 및 고찰

아쉬웠던 점

1 데이터 측면



데이터 샘플 수 부족으로 인한
계절성 반영 부족, 이상 상황 데이터 부족

데이터를 1시간 단위로 집계하면서
변동성이 감소해 세부 운영 아이디어
적용에 한계가 있었음

2 한전 요금 체계와 불일치



요금 항목별 전력 산정 단위(15분)와
예측 단위(1시간)가 상이해
각 단위별 예측 모델을 별도로 운영함

3 경제적 성과



월간 전력 요금(기본 요금+전력량 요금)이
약 수십억 원인 반면,
절감액은 수십만 원 수준으로
단기적인 경제적 성과는 크지 않았음

Q&A

감사합니다