

I. 참가자 정보

공모명	제4회 BDA 채용연계 데이터 분석 공모전
성명	사달라_조문영

II. 세부 내용

1. 문제 정의 및 제안 배경

1-1. 문제 정의

현재 스마트 팩토리 운영 환경에서 발생하는 주요 문제점은 다음과 같다. 첫째, 스마트 팩토리 특성 상 이상 설비 발견 시 사후 대응에 한계가 있다. 스마트 팩토리는 AI가 공정과 설비를 24시간 자동으로 제어하는 구조로 운영되며, 인적 개입이 최소화된다는 특성을 갖는다. 이러한 운영 환경에서는 설비 이상이 발생하더라도 즉각적인 조치가 어려워 사후 대응으로 이어질 가능성이 높고, 그 결과 공정 중단 및 생산 차질로 연결될 위험이 크다. 둘째, 비효율적인 전력 소비 패턴에 따른 전력 요금이 높게 부과되는 것이다. 산업용 전기요금 체계는 시간대별로 단가가 다른 계시별 요금제와 월간 최대 피크 전력에 연동되는 기본요금제로 구성되어 있으며, 전력 사용 시점이 비용에 결정적인 영향을 미친다. 그러나 현재 운전 방식은 요금 단가가 높은 시간대나 피크 시간대에 전력 소비가 집중되는 경향을 보이고 있어 불필요한 비용이 과다 발생하고 있다.

구분	단가(원/kWh)	해당 시간대
경부하	105.6	22:00~08:00
중간부하	127.9	08:00~11:00,12:00~13:00,18:00~22:00
고부하	158.2	11:00~12:00,13:00~18:00

1-2. 제안 배경 및 필요성

본 프로젝트의 목표는 공장 전체 및 설비별 전력 사용 데이터를 기반으로

1. 이상 전력 패턴 사전 탐지
2. TOU 요금제 기반 전력 비용 최소화 스케줄링

을 통합적으로 구현하여, 설비 신뢰성·생산 안정성·에너지 비용 효율·ESG 경영 성과를 동시 향상시키는 것이다.

이상 전력 패턴 사전 탐지 시스템은 설비 이상을 조기에 감지하기 위해, 예측된 정상 전력 범위에서 크게 이탈하는 구간을 위험 구간으로 정의하고 경고 알람을 제공하는 방식으로 설계되었다. 5월 예측 소비 전력 분석 결과, 공장 전체 평균 전력은 약 39,106 kW이며 표준편차가 약 8.2 kW 수준으로 변동폭이 매우 작은 안정적 소비 패턴을 보였다. 이러한 환경에서는 피크 전력 감소나 단순 이상치 제거보다, 장비별 전력 사용이 정상 범위를 벗어나는 구간을 이상 신호로 해석하는 접근이 더 효과적이다. 이에 각 장비의 전력이 99% 신뢰구간 밖에 존재하는 값을 위험 구간으로 설정하여, 이상 징후를 조기에 탐지하고 사전 대응 체계를 구축하도록 분석 아이디어를 구체화하였다.


TOU 기반 최적 스케줄링 분석은, 복잡한 요금 체계와 설비 제약 조건 하에서 기존 수동 관리 방식이 갖는 비용 효율성의 한계를 극복하기 위해 수행되었다. 본 분석은 수리적 최적화 기법인 선형계획법(Linear Programming)을 적용하여 모델링을 수행하였다. 우선 과거 전력 소비 패턴과 계시별 요금 테이블(TOU)을 결합하여 전력 비용이 최소가 되도록 목적함수를 설정하였으며, 일일 총 전력 소비량은 보존하되 설비가 감당 가능한 변동폭(Ramp Rate) 범위 내에서만 부하가 재배치되도록 제약조건을 적용하였다. 이 모델링은 피크 전력을 저감하고 고비용 시간대의 부하를 저비용 시간대로 이동시키는 스케줄을 도출함으로써, 총 에너지 사용량을 유지한 상태에서 전력 비용 구조를 근본적으로 개선할 수 있음을 제시한다.

2. 모델링 수행 과정 및 선정 결과

2-1. 데이터 탐색 및 전처리

1. 데이터 정제

노이즈 및 중복 변수 제거: **accumActiveEnergy**와 계산 중복 항목을 제거하여 모델이 순수 전력



변화량에 집중하게 하였다.

2. 피쳐 엔지니어링

시계열 데이터의 특성을 반영하기 위해 **Lag**과 주기성을 수치화했다.

- 시계열 특성 추출: 직전 1시간(**Lag 1**) 및 전일 동시간(**Lag 24**) 지연값과 24시간 이동평균(**Rolling 24**) 변수를 생성하여 초단기 변동과 장기 추세를 동시에 반영했다.
- 주기성 및 패턴 반영: 시간(**Hour**), 요일(**Weekday**), 휴무일 변수를 수치화하여 공장의 반복적인 조업 루틴을 학습시켰다.
- 가동 상태(**Operation**) 로직 적용: 설비 가동 여부를 핵심 변수로 설정하였으며, 설비가 가동되지 않는 상태(**0**)일 경우 예측값 또한 **0**으로 출력 로직을 구성했다.

전압 및 전류의 단순 평균값은 순간적인 설비 상태를 반영하는 데에는 유용하지만, 전력 수요는 본질적으로 과거 사용 이력에 강하게 의존하는 시계열 데이터라는 점에 착안하였다. **EDA** 결과, 전력 사용량은 시간대별·일별 주기성과 함께 직전 시점 및 전일 동일 시점의 사용 패턴이 반복적으로 나타나는 경향을 보였다. 이에 따라 단순 물리량보다 과거 전력 소비 패턴을 직접적으로 반영하는 **lag** 및 **rolling** 변수를 미래 사용량 예측에 가장 높은 설명력을 갖는 핵심 피쳐로 선정하였다.

성능 검증을 위해 데이터셋을 시계열 순서에 따라 다음과 같이 분할하였다:

- 학습 데이터 (**Train**): 2024.12.01 ~ 2025.03.31 (2,879행, 약 80.5%)
- 테스트 데이터 (**Test**): 2025.04.01 ~ 2025.04.30 (697행, 약 19.5%)

2-2. 적용한 모델 구조 및 학습 방식 설명

사용한 모델

1. 부스팅

- **XGBoost**: 성능과 속도 면에서 좋은 그라디언트 부스팅 알고리즘이다.. 기본 모델과 하이퍼파라미터 튜닝된 모델 두 가지를 사용하였다.
- **LightGBM**: 학습 속도가 빠른 부스팅 모델이다.. 마찬가지로 기본 모델과 하이퍼파라미터 튜닝된 모델 모두 테스트하였다.
- **CatBoost**: 범주형 데이터 처리와 과적합 방지에 특화된 모델이다.

2. 배깅

- **RandomForest**: 여러 개의 결정 트리를 만들고 그 결과를 평균 내어 예측하는 모델로 과적합 방지에 강점이 있다.

3. 앙상블

- **Voting Regressor**: 앞서 학습된 상위 2개의 우수 모델의 예측값을 평균 내어 예측의 안정성을 높인다.
- **Stacking Regressor**: 여러 모델의 예측 결과를 모아서 또 다른 모델이 최종 값을 예측하도록 학습하는 기법이다.

4. 시계열 모델 :

- **Prophet**: 휴일, 계절성처리에 강점이 있다. **cmdstanpy** 로그를 통해 학습 상태를 알 수 있다.

- **ARIMA** : 전통적인 통계적 시계열 분석 방법으로, 데이터의 추세와 차분을 고려하여 예측한다.
5. 딥러닝 모델
- **LSTM**: RNN의 장기 의존성 문제를 해결하고 긴 시퀀스 데이터에서도 과거의 정보를 효율적으로 기억할 수 있는 **LSTM** 모델로 학습하였다.


하이퍼파라미터 최적화

- 도구: **Optuna**프레임워크를 사용한다.
- 대상: **XGBoost, LightGBM, CatBoost, RandomForest,**
- 방법: 트리 개수, 트리 깊이, 학습률 등의 파라미터 조합을 무작위로 탐색하여 검증 데이터에 대한 **SMAPE** 점수가 가장 낮은 조합을 찾아낸다.


최적 모델 선정

- 학습된 모든 모델을 검증 데이터로 평가한다.
- **SMAPE** 에러가 가장 낮은 하나의 모델로 선정한다.
- 선정된 모델은 전체 데이터(학습+검증)로 다시 한번 재학습하여 5월 데이터를 예측한다.

2-3. 모델별 성능 비교 및 평가




RandomForest 모델의 변수 중요도를 분석한 결과 **24시간 이동평균**이 약 **55.5%**로 가장 높은 기여도를 보였다. 특정 시점의 단편적인 값보다 최근 **24시간**의 평균적인 전력 소비 추세가 미래 예측에 중요한 지표임을 볼 수 있다.



RandomForest, XGBoost, LightGBM, ARIMA, Prophet 등 변수 조합에 대해 총 18건의 실험을 수행했다. 평가 지표는 SMAPE를 기준으로 하였으며 상위 5개 모델의 성능 요약은 아래 표와 같다.

Model	MAE	RMSE	SMAPE (%)
Voting	77.0905	95.7276	0.1970
RandomForest	77.2385	96.2779	0.1974
CatBoost	77.3741	95.8099	0.1977
ARIMA	79.7669	98.8645	0.2039
Stacking	81.6211	102.4369	0.2086
XGBoost	81.6269	102.7298	0.2086
LightGBM	92.1705	164.7514	0.2350

분석 결과 전력 데이터는 직전 시간대의 패턴을 반영했을 때 예측 성능이 가장 우수하다. 이에 단일 모델 중 성능이 가장 뛰어난 RandomForest와 CatBoost를 결합한 앙상블 모델을 최종 모델로 선정하여 2025년 5월 전력 수요를 예측했다.



3. 결론 및 기대효과

3-1. 프로젝트 핵심 성과 및 고찰

1. Objective Function (목적함수)

$$\text{Minimize } Z = \sum_{t=1}^T (C_t \cdot P_t) + \alpha \cdot P_{peak} + \beta \sum_{t=2}^T |P_t - P_{t-1}|$$

2. Subject to (제약조건)

- 1) $\sum_{t \in D_k} P_t = E_{total,k} \quad (\forall k \in \text{Days})$
- 2) $|P_t - P_{t-1}| \leq \Delta P_{limit} \quad (\forall t)$
- 3) $P_t \leq P_{peak} \quad (\forall t)$
- 4) $P_{min} \leq P_t \leq P_{max} \quad (\forall t)$

3. Nomenclature (변수 정의)

P_t : 시간 t 의 최적 전력 사용량 (kW)

P_{peak} : 월간 최대 수요 전력 (kW)

C_t : 계시별 요금 단가 (원/kWh)

α : 기본요금 단가 (원/kW)

β : 변동성 억제 가중치

$E_{total,k}$: 기존 일일 총 전력 소비량 (kWh)

ΔP_{limit} : 시간당 허용 최대 변동폭 (kW)

$P_{min/max}$: 설비 가동 최소/최대 한계값

TOU 기반 선형계획법 최적 스케줄링을 적용한 결과, 기존 전력 사용은 주로 고비용 시간대(Heavy/Peak Load 구간)에 집중되어 있었으나, 최적화 이후 부하가 저비용 시간대(Light Load 구간)로 재배치되는 형태로 개선되었다. 그래프에서 확인되듯이, 기존 스케줄에서는 8~18시 구간에서 전력 사용이 높게 유지되는 반면, 최적 스케줄에서는 해당 구간의 부하를 감축하고 0~7시 및 19~23시의 저단가 시간대로 이동시킴으로써 전력 사용 곡선이 완만하게 분산되었다. 이러한 부하 시프트를 통해 총 전력 사용량은 동일하게 유지하면서도, 피크 구간의 전력 집중을 완화하고 고비용 시간대 전력 사용을 저감하는 효과를 달성하였다.

[BASE] 15분 기준 월 최대수요전력: 39,404.868 kW

39149.6507

1174.489521

[월] Base 총요금: 3,499,204,706 원

[월] Opt 총요금: 3,498,838,042 원

[월] 총요금 절감액: 366,664 원

[월] Opt 월 피크(P_peak): 39,113.536 (kW 근사)

5월 예측 요금이 3,499,204,706원에서 3,498,838,042원으로 총 366,664원 절약하였다. 연간 약 450만원 가량 비용 절감의 효과가 있다.

1. 경제적 성과 창출의 한계

- 한계점: 현재 구축된 고정밀 모델을 통한 직접적인 전력 요금 절감액은 월 약 30만 원 수준으로 분석되었다.

2. 15분 단위 피크 대응력 부족 (한전 요금 체계와의 괴리)

- 한계점: 현재 모델은 1시간 단위 예측에 최적화되어 있으나, 실질적인 기본 요금을 결정하는 '최대수요전력'은 15분 단위로 산정된다.

3. 모델 구조의 확장성 및 하이브리드화

- 개선 방향: 현재의 머신러닝 앙상블 모델에 장기 추세 학습에 강한 딥러닝(LSTM, Transformer)을 결합한 하이브리드 구조 도입을 검토 중이다. 이를 통해 장기 에너지 수급 계획과 실시간 피크 관리를 동시에 수행하는 통합 에너지 관리 시스템(EMS)으로 발전시킬 계획이다.